취준공시 요구사항 정의서

작성 기준: 2026-10-23 / 개인 프로젝트 / 지역·반·성명: 미기입

서비스와 데이터

재무 초보 취업 준비생이 지원 기업의 공시를 이해하도록 돕는 RAG 서비스다. 영화 데이터는 메타데이터 예시이며 실제 도메인은 기업 공시다. 금융·IT·제조 등 고유 기업 100개, 2025.12 연간 사업보고서 100건을 기준 자료로 사용한다. 공시 접수일 검색 범위는 2026-01-01~2026-10-22 스냅샷이다.

- 전체 파싱 4,856개 섹션, 80,235,841자. 전체 본문 120,008개 청크를 두 문서 컬렉션에 나눠 검색한다.

- 기존 large 21,374개를 보존하고 중복을 제외한 98,634개를 small으로 확장했다.

- 실제 검증에서 카카오뱅크 2026.03 분기보고서 1건을 추가 수집·색인했다. 이 추가 문서는 위 연간 100건의 수치와 구분한다.

- 메타데이터: 기업명·종목명·코드·업종·보고기간·사업 개요 원문 발췌. 항목당 텍스트 1건이다.

- 근거가 필요한 질문: 사업부문 구성, 금융지주/은행 구분, 영업점과 고객센터 차이, 연간·분기 사업 구분, 평균 급여와 초봉 차이.

기능 요구사항 대조표

필수 F2001~F2012의 구현과 실행 검사를 마쳤다. F2004/F2005는 이번에 확장했다. 첨부된 공식 양식으로 셀프 체크리스트를 별도 작성했다. 실제 상호 점검은 미실시다.

ID	구분	요구사항	현재 상태	코드	근거·제한
F2001	필수	기업 메타데이터 적재	구현	collection.py / company_records	고유 기업 100개, 기업별 index_text 1개. 증거: probe.json
F2002	필수	메타데이터 색인	구현	vector_store.py	100개, 고정 기업 ID, 재실행 신규 입력·요청 0회
F2003	필수	P1 검색어 추출	구현	report_selection.py / SearchPlan	gpt-6.1-sol 실제 JSON 검색어 확보. 자체 사업보고서 required 강제
F2004	필수	P2 문서 선별·수집	보완 완료	pipeline.py / report_selection.py / report_preparation.py	P1 유형별 A001/A002/A003 후보 > P2 > ZIP/파싱 > 추가 보고서 전문 small 색인 > 선택 접수번호 검색. 실제 연간+분기 전체 실행 검증
F2005	필수	별도 문서 컬렉션·청킹	보완 완료	chunking.py / vector_store.py	연간 100건 전체 4,856개 섹션·120,008개 청크. 기존 large 21,374 + 신규 small 98,634. 본문 위치·합집합·실제 DB 검증
F2006	필수	검색·병합·중복 제거	구현	vector_store.py / answering.py	기업 메타데이터 고정 + 모델별 검색/기업·선택 접수번호 필터 + RRF 순위 병합. 모델 간 거리 직접 비교 금지
F2007	필수	근거 기반 답변·LangGraph	구현	qa_graph.py / answering.py	retrieve/generate 2노드. 문서 없음은 확인 불가 응답, 미래 초봉 실제 질문 거절 확인
F2008	필수	실제 사용 근거 표시	보완 완료	answering.py / ui_support.py / app.py	잘못된 번호 차단. 무인용 안내 추가. 답변 근거와 추천 질문 추가 근거를 구분

ID	구분	요구사항	현재 상태	코드	근거·제한
F2009	필수	기업 선택·기업별 대화	구현	app.py / ui_support.py	100개 선택, 세션별 기록 분리·왕복 복원. 재접속 후 영구 복원은 범위 외
F2010	필수	취업 준비 특화 기능	구현	briefing.py / app.py	근거 발췌 ID 기반 브리핑·면접 연습 질문. 저장본 4개, 다른 기업은 CLI 생성
F2011	필수	자연어 기업 탐색	구현	company_search.py	후보 최대 12개, 조건별 발췌 검사, 최대 5개 결과, 기업 화면 이동. 그룹·종속회사 포함 해석은 이유에 표시
F2012	필수	진행·오류·금융 안내	구현	app.py / cli.py	실제 진행 상태와 격리 시나리오의 색인 없음·키 누락·무인용 안내 캡처. 전문가 확인 안내
F2013	심화	독립 HTML/CSS/JS 프론트엔드	미선택·미구현	Streamlit 단일 앱	CSS 조정은 했지만 프론트/서버 분리와 독립 API 계약을 구현한 것은 아님
F2014	심화	MMR 검색	미선택·미구현	hybrid + RRF	하이브리드 검색은 MMR이 아님. 다양성 선택 및 비교 실험 미구현
F2015	심화	RAG 전후 품질 비교	구현·산출물 추가	evaluation.py / evaluate_rag.py	동일 모델·질문 5쌍의 실제 비교 보관. 이 결과는 혼합 확장 전 large 코퍼스 기준이며 혼합 모드 5쌍 재실행은 하지 않음
F2016	심화	서로 다른 문서 출처 결합	미선택·미구현	OpenDART / DART 공시	기업 메타데이터와 공시 XML 구분만으로 위키·PDF 등 이종 출처 결합을 구현한 것은 아님

비기능 요구사항

ID	요구사항	현재 상태	검증·제한
NF2001	응답 시간	표본 확인	기존 비교의 전체 P1/P2 표본 20초와 혼합 다중 보고서 표본 51.4초를 구분. 최초 추가 색인 포함 여부가 달라 직접 성능 비교 불가
NF2002	수집·색인 캐시	검증 통과	기존 large·small 확장·추가 분기 문서 재실행에서 신규 임베딩/API 0회 확인. P1/P2 채팅은 별도
NF2003	API 키 관리	검증 통과	환경변수 사용. .env 제외. 제출 패키지는 실제 인증키 값 대조 검사 수행
NF2004	내부 정보 비노출	표본 확인	UI 모의 실패 테스트와 키 누락 화면 확인. 화면에 전체 프롬프트·추적 정보 표시하지 않음
NF2005	모듈 분리	구현	수집·청킹·색인·검색·생성·UI 분리, JSON/해시/시각 common.py, 모델 호출 llm.py로 통합
NF2006	외부 API 예절	구현·제한 기록	DART 0.35초 간격/최대 3회, 임베딩 호출 시작 간격 0.5초 공유, 최대 4개 동시 요청, SDK 재시도 2회. 실제 호출 한도는 제공자 설정에 따름
NF2007	출처·이용 조건	기록 완료	OpenDART 약관·공시 제출인 권리 구분 및 원문 URL 기록. SUITE/KCC OFL 전문 보관. 일괄 무제한 재배포 허가로 해석하지 않음

범위와 출처

보고서 유형은 사업·반기·분기이며 한 질문에서 최대 6개를 선별한다. 기업 자체 대표 사업보고서는 항상 포함한다. 임의의 모든 연도/외부 문서를 처리하는 서비스는 아니다. 수치 계산 엔진, 실시간 채용/금리 정보, 로그인·대화 영구 저장은 제공하지 않는다.

원본 과제 정의서 23쪽의 요구와 실제 코드를 대조했다. 문서에 적힌 외부 업로드나 상호 점검을 사용자 승인 또는 수행 완료 증거로 취급하지 않았다. 원본 과제 PDF는 제출 ZIP에 포함하지 않는다. 데이터·폰트 이용 조건은 실행기록/data_sources.md, 실행기록/FONT_LICENSES.md 및 프로젝트 licenses/에 기록했다.